



(12) 发明专利

(10) 授权公告号 CN 119991689 B

(45) 授权公告日 2025. 09. 19

(21) 申请号 202510126909.X

(22) 申请日 2025.01.27

(65) 同一申请的已公布的文献号

申请公布号 CN 119991689 A

(43) 申请公布日 2025.05.13

(73) 专利权人 四川大学

地址 610000 四川省成都市一环路南一段
24号

(72) 发明人 韦乐涛 范嘉豪 张帅 余星燃
王劲东

(74) 专利代理机构 四川伯诚志专利代理事务
所(普通合伙) 51440

专利代理师 钟睿

(51) Int. Cl.

G06T 7/10 (2017.01)

G06T 7/00 (2017.01)

G06V 10/77 (2022.01)

G06V 10/764 (2022.01)

G06V 10/774 (2022.01)

G06V 10/80 (2022.01)

G06V 10/82 (2022.01)

G06T 5/50 (2006.01)

G06N 3/0464 (2023.01)

G06N 3/048 (2023.01)

G06N 3/084 (2023.01)

G06F 17/16 (2006.01)

G06F 17/18 (2006.01)

(56) 对比文件

CN 118196121 A, 2024.06.14

CN 118552726 A, 2024.08.27

CN 115187530 A, 2022.10.14

审查员 郭皓


权利要求书2页 说明书8页 附图2页

(54) 发明名称

一种基于神经网络的乳腺超声图像分割方法

(57) 摘要

本发明公开了一种基于神经网络的乳腺超声图像分割方法,属于图像处理技术领域,包括以下步骤:S1、采集乳腺超声图像,利用卷积层对乳腺超声图像依次进行卷积处理和展平处理;S2、进行特征提取,得到原始特征图;S3、进行重塑处理和扁平化处理,得到展平特征图;S4、将展平特征图输入至卷积特征提取模块中,得到低层特征图;S5、将低层特征图输入至卷积注意力模块中,得到加权特征图;S6、将原始特征图和加权特征图输入至交叉注意力模块中,得到最终特征图;S7、完成乳腺超声图像分割。本发明利用管道注意力与空间注意力的结合降低卷积低级特征图中的噪声干扰,避免为深层网络引入过多噪声,缓解了噪声对分割结果的影响。



1. 一种基于神经网络的乳腺超声图像分割方法,其特征在于,包括以下步骤:

S1、采集乳腺超声图像,利用卷积层对乳腺超声图像依次进行卷积处理和展平处理;

S2、对处理后的乳腺超声图像进行特征提取,得到原始特征图;

S3、对原始特征图进行重塑处理和扁平化处理,得到展平特征图;

S4、将展平特征图输入至卷积特征提取模块中,得到低层特征图;

S5、将低层特征图输入至卷积注意力模块中,得到加权特征图;

S6、将原始特征图和加权特征图输入至交叉注意力模块中,得到最终特征图;

S7、将最终特征图依次输入至下采样卷积层和上采样卷积层,完成乳腺超声图像分割;

所述S5包括以下子步骤:

S51、利用卷积注意力模块的通道注意力层对低层特征图进行全局平均池化和全局最大池化,得到第一通道描述符和第二通道描述符,并利用第一通道描述符和第二通道描述符对低层特征图进行处理;

S52、利用卷积注意力模块的空间注意力层对处理后低层特征图进行全局平均池化和全局最大池化,得到第一空间描述符和第二空间描述符,并利用第一空间描述符和第二空间描述符得到加权特征图;

所述S6包括以下子步骤:

S61、利用交叉注意力模块的线性层将原始特征图映射为查询矩阵,将加权特征图映射为键矩阵和值矩阵;

S62、计算查询矩阵和键矩阵之间的注意力分数矩阵,得到每个键对查询矩阵的归一化注意力权重;

S63、根据每个键对查询矩阵的归一化注意力权重以及值矩阵,计算加权后的输出特征;

S64、将加权后的输出特征和查询矩阵,得到融合特征图;

S65、通过线性变换将融合特征图映射回原始特征空间,得到最终特征图。

2. 根据权利要求1所述的基于神经网络的乳腺超声图像分割方法,其特征在于,所述S4中,卷积特征提取模块包括第一标准卷积层、第一扩张卷积层、深度可分离卷积层、第二扩张卷积层、第二标准卷积层、残差卷积层和加法器;

所述第一标准卷积层的输入端作为卷积特征提取模块的输入端,所述第一标准卷积层的输入端还与残差卷积层的输入端连接;所述第一标准卷积层的输出端和第一扩张卷积层的输入端连接;所述第一扩张卷积层的输出端和深度可分离卷积层的输入端连接;所述深度可分离卷积层的输出端和第二扩张卷积层的输入端连接;所述第二扩张卷积层的输出端和第二标准卷积层的输入端连接;所述第二标准卷积层的输出端和加法器的第一输入端连接;所述残差卷积层的输出端和加法器的第二输入端连接;所述加法器的输出端作为卷积特征提取模块的输出端。

3. 根据权利要求1所述的基于神经网络的乳腺超声图像分割方法,其特征在于,所述S51中,第一通道描述符 M_{avg} 的计算公式为:

$$M_{avg} = AvgPool(F);$$

式中, F 表示低层特征图, $AvgPool(\bullet)$ 表示全局平均池化操作;

所述S51中,第二通道描述符 M_{max} 的计算公式为:

$$M_{max} = \text{MaxPool}(F);$$

式中, $\text{MaxPool}(\bullet)$ 表示全局最大池化操作;

所述S51中,处理后低层特征图 F' 的表达式为:

$$F' = F \bullet A_c;$$

$$A_c = \sigma(\text{FC}(\text{ReLU}(\text{FC}(M_{avg} + M_{max}))));$$

式中, A_c 表示多层感知机网络中每个通道的注意力权重, $\text{ReLU}(\bullet)$ 表示激活函数, $\sigma(\bullet)$ 表示Sigmoid激活函数, FC 表示全连接层。

4.根据权利要求1所述的基于神经网络的乳腺超声图像分割方法,其特征在于,所述S52中,第一空间描述符 M_{avg}' 的计算公式为:

$$M_{avg}' = \text{AvgPool}(F');$$

式中, F' 表示处理后低层特征图, $\text{AvgPool}(\bullet)$ 表示全局平均池化操作;

所述S52中,第二空间描述符 M_{max}' 的计算公式为:

$$M_{max}' = \text{MaxPool}(F');$$

式中, $\text{MaxPool}(\bullet)$ 表示全局最大池化操作;

所述S52中,加权特征图 F'' 的表达式为:

$$F'' = F' \bullet A_s;$$

$$A_s = \sigma(\text{Conv}([M_{avg}'; M_{max}']));$$

式中, A_s 表示空间注意力权重图, Conv 表示卷积操作, $\sigma(\bullet)$ 表示Sigmoid激活函数, $[\bullet; \bullet]$ 表示拼接操作。

5.根据权利要求1所述的基于神经网络的乳腺超声图像分割方法,其特征在于,所述S62中,注意力分数矩阵 A 的表达式为:

$$A = \frac{QK^T}{C};$$

式中, Q 表示查询矩阵, K 表示键矩阵, T 表示矩阵转置, C 表示通道数;

所述S62中,每个键对查询矩阵的归一化注意力权重 α 的计算公式为:

$$\alpha = \text{Softmax}(A);$$

式中, $\text{Softmax}(\bullet)$ 表示Softmax激活函数。

6.根据权利要求1所述的基于神经网络的乳腺超声图像分割方法,其特征在于,所述S63中,加权后的输出特征 O 的计算公式为:

$$O = \alpha V;$$

式中, α 表示每个键对查询矩阵的归一化注意力权重, V 表示值矩阵;

7.根据权利要求1所述的基于神经网络的乳腺超声图像分割方法,其特征在于,所述S64中,融合特征图 Q_{fused} 的计算公式为:

$$Q_{fused} = Q + O;$$

式中, O 表示加权后的输出特征, Q 表示查询矩阵。

一种基于神经网络的乳腺超声图像分割方法

技术领域

[0001] 本发明属于图像处理技术领域,具体涉及一种基于神经网络的乳腺超声图像分割方法。

背景技术

[0002] 目前,卷积神经网络(Convolutional Neural Network,CNN)在医学图像分割领域已经取得了较大成功,推动了智能诊断技术的迅猛发展。在乳腺超声图像分割领域,CNN充分利用肿瘤病灶在超声图像中的局部连续分布等先验知识,通过卷积核的局部感受野提取肿瘤区域的形态特征,并有效地从背景中分离出来,实现肿瘤病灶的自动分割。具体而言,每个卷积核会专注于图像的局部区域进行特征提取,而不是一次性处理整个图像。这种局部处理方式能有效地捕捉图像中不同位置的纹理、边缘和形状等局部特征,通过多层卷积和池化的堆叠,CNN能够逐渐学习到从低级到高级的特征。在乳腺超声图像中,CNN将首先学习纹理和边缘等局部特征,这些特征在肿瘤区域与背景区域会有较为显著的差异;随着网络的深入,卷积核学习到的特征将更加抽象,可以识别更大的结构,如肿瘤的形状和边界等。然而,由于卷积核的局部感受野,其提取的特征往往缺乏全局性,此外,相较于其他图像,超声图像往往对比度低,边缘模糊且存在局部噪声,搭建CNN超声图像分割网络往往面临局部噪声干扰,特征提取困难造成分割结果不准确等问题。

[0003] Transformer最早在自然语言处理领域取得成功,它通过自注意力机制来建立输入序列中各个元素之间的全局关系,具有强大的全局建模能力。随着计算机视觉领域的不断发展,Transformer被应用于图像处理中,其通过自注意力机制捕捉图像中远距离像素之间的依赖关系,克服了传统CNN中局部感受野的限制,有效抑制了图像噪声对于特征提取的影响。尽管Transformer在图像处理中具有极大优势,但由于计算量较大,直接对整张图像进行自注意力计算往往带来昂贵的算力需求。因此,基于窗口自注意力机制的Transformer被提出,旨在保证全局性的同时降低计算复杂度。

[0004] Swin Transformer是一种高效的视觉Transformer架构,其核心是引入了窗口自注意力机制以及滑动窗口机制,保留Transformer在捕捉全局上下文信息方面优势的同时大大降低了计算复杂度。窗口自注意力机制通过将图像划分为多个小的窗口,每个窗口内部执行自注意力计算,从而减少计算量,使得每个窗口内的自注意力计算只涉及局部区域的像素,显著降低了计算复杂度。为了解决窗口自注意力导致的信息传播局限性,每个窗口只能学习到局部信息,无法有效地建模不同窗口之间的长程依赖,其引入了滑动窗口机制,通过对窗口进行“滑动”操作,使多个Transformer层之间窗口之间的关系能够被逐渐捕捉。具体来说,在每一层,Swin Transformer首先将输入图像划分成固定大小的窗口,进行自注意力计算;然后,在下一个层次中,将窗口的位置向一个固定方向偏移(如左移或上移)。通过这种方式,窗口之间的交集在每一层都会发生变化,从而可以逐步实现跨窗口的信息传递。这样,信息可以在多个层次之间逐渐汇聚,最终完成全局信息的建模。通过多层次的窗口偏移,Swin Transformer不仅可以在每个层次内提取局部信息,还能在层次之间逐步捕

捉长程依赖关系,从而增强了全局建模能力。

[0005] Swin Transformer通过窗口自注意力机制和滑动窗口机制降低Transformer计算复杂度的同时,实现了全局和局部信息的把握,缓解了CNN在乳腺超声图像分割中的局部感受野和噪声干扰等问题。然而,在乳腺超声图像分割任务中,肿瘤病灶往往具有不同尺寸和复杂的边界,需要精细分割,而Swin Transformer采用固定的窗口大小,其在处理不同尺度的物体时,窗口大小可能无法有效适应不同物体的尺寸,特别是对于较小的局部区域,窗口自注意力无法充分提取小的肿瘤病灶或复杂纹理边界等局部细节信息。此外,Swin Transformer的设计侧重于全局建模,而过多的全局建模可能导致局部特征不够精细,尤其是在面对边缘、边界或微小物体时,使其难以实现乳腺超声图像中肿瘤病灶的精细分割。

[0006] 在乳腺超声图像分割中,CNN由于其局部感受野的特点,能够有效捕捉肿瘤病灶与背景之间的差异,通过多层卷积逐渐学习从低级到高级的特征。然而,CNN的局部感受野限制了其全局信息的提取,且超声图像通常存在对比度低、边缘模糊和噪声干扰的问题,这使得CNN在处理细节时可能面临特征提取困难和分割结果不准确的问题;Transformer通过自注意力机制能够捕捉图像中的远距离像素依赖,克服了CNN的局部感受野限制。Swin Transformer进一步通过窗口自注意力机制和滑动窗口机制减少计算复杂度,保证了全局信息的建模能力。然而,Swin Transformer在处理不同尺度物体时可能无法有效适应各种尺寸,且过度关注全局信息可能导致局部细节的丧失,尤其在处理复杂边界或小物体时。因此,如何充分结合CNN和Swin Transformer的优势,构建一个既能有效建模全局信息又能精准捕捉局部细节特征的乳腺超声图像分割网络成为了一个重要的问题。

发明内容

[0007] 本发明为了解决以上问题,提出了一种基于神经网络的乳腺超声图像分割方法。

[0008] 本发明的技术方案是:一种基于神经网络的乳腺超声图像分割方法包括以下步骤:

[0009] S1、采集乳腺超声图像,利用卷积层对乳腺超声图像依次进行卷积处理和展平处理;

[0010] S2、对处理后的乳腺超声图像进行特征提取,得到原始特征图;

[0011] S3、对原始特征图进行重塑处理和扁平化处理,得到展平特征图;

[0012] S4、将展平特征图输入至卷积特征提取模块中,得到低层特征图;

[0013] S5、将低层特征图输入至卷积注意力模块中,得到加权特征图;

[0014] S6、将原始特征图和加权特征图输入至交叉注意力模块中,得到最终特征图;

[0015] S7、将最终特征图依次输入至下采样卷积层和上采样卷积层,完成乳腺超声图像分割。

[0016] 进一步地,S4中,卷积特征提取模块包括第一标准卷积层、第一扩张卷积层、深度可分离卷积层、第二扩张卷积层、第二标准卷积层、残差卷积层和加法器;

[0017] 第一标准卷积层的输入端作为卷积特征提取模块的输入端,第一标准卷积层的输入端还与残差卷积层的输入端连接;第一标准卷积层的输出端和第一扩张卷积层的输入端连接;第一扩张卷积层的输出端和深度可分离卷积层的输入端连接;深度可分离卷积层的输出端和第二扩张卷积层的输入端连接;第二扩张卷积层的输出端和第二标准卷积层的输

入端连接；第二标准卷积层的输出端和加法器的第一输入端连接；残差卷积层的输出端和加法器的第二输入端连接；加法器的输出端作为卷积特征提取模块的输出端。

[0018] 进一步地，S5包括以下子步骤：

[0019] S51、利用卷积注意力模块的通道注意力层对低层特征图进行全局平均池化和全局最大池化，得到第一通道描述符和第二通道描述符，并利用第一通道描述符和第二通道描述符对低层特征图进行处理；

[0020] S52、利用卷积注意力模块的空间注意力层对处理后低层特征图进行全局平均池化和全局最大池化，得到第一空间描述符和第二空间描述符，并利用第一空间描述符和第二空间描述符得到加权特征图。

[0021] 进一步地，S51中，第一通道描述符 M_{avg} 的计算公式为：

[0022] $M_{avg} = \text{AvgPool}(F)$ ；

[0023] 式中， F 表示低层特征图， $\text{AvgPool}(\cdot)$ 表示全局平均池化操作；

[0024] S51中，第二通道描述符 M_{max} 的计算公式为：

[0025] $M_{max} = \text{MaxPool}(F)$ ；

[0026] 式中， $\text{MaxPool}(\cdot)$ 表示全局最大池化操作；

[0027] S51中，处理后低层特征图 F' 的表达式为：

[0028] $F' = F \cdot A_c$ ；

[0029] $A_c = \sigma(\text{FC}(\text{ReLU}(\text{FC}(M_{avg} + M_{max}))))$ ；

[0030] 式中， A_c 表示多层感知神经网络中每个通道的注意力权重， $\text{ReLU}(\cdot)$ 表示激活函数， $\sigma(\cdot)$ 表示Sigmoid激活函数， FC 表示全连接层。

[0031] 进一步地，S52中，第一空间描述符 M_{avg}' 的计算公式为：

[0032] $M_{avg}' = \text{AvgPool}(F')$ ；

[0033] 式中， F' 表示处理后低层特征图， $\text{AvgPool}(\cdot)$ 表示全局平均池化操作；

[0034] S52中，第二空间描述符 M_{max}' 的计算公式为：

[0035] $M_{max}' = \text{MaxPool}(F')$ ；

[0036] 式中， $\text{MaxPool}(\cdot)$ 表示全局最大池化操作；

[0037] S52中，加权特征图 F'' 的表达式为：

[0038] $F'' = F' \cdot A_s$ ；

[0039] $A_s = \sigma(\text{Conv}([M_{avg}'; M_{max}']))$ ；

[0040] 式中， A_s 表示空间注意力权重图， Conv 表示卷积操作， $\sigma(\cdot)$ 表示Sigmoid激活函数， $[\cdot; \cdot]$ 表示拼接操作。

[0041] 进一步地，S6包括以下子步骤：

[0042] S61、利用交叉注意力模块的线性层将原始特征图映射为查询矩阵，将加权特征图映射为键矩阵和值矩阵；

[0043] S62、计算查询矩阵和键矩阵之间的注意力分数矩阵，得到每个键对查询矩阵的归一化注意力权重；

[0044] S63、根据每个键对查询矩阵的归一化注意力权重以及值矩阵，计算加权后的输出特征；

[0045] S64、将加权后的输出特征和查询矩阵，得到融合特征图；

[0046] S65、通过线性变换将融合特征图映射回原始特征空间,得到最终特征图。

[0047] 进一步地,S62中,注意力分数矩阵A的表达式为:

$$[0048] \quad A = \frac{QK^T}{C};$$

[0049] 式中,Q表示查询矩阵,K表示键矩阵,T表示矩阵转置,C表示通道数;

[0050] S62中,每个键对查询矩阵的归一化注意力权重 α 的计算公式为:

$$[0051] \quad \alpha = \text{Softmax}(A);$$

[0052] 式中,Softmax($\bullet$)表示Softmax激活函数。

[0053] 进一步地,S63中,加权后的输出特征O的计算公式为:

$$[0054] \quad O = \alpha V;$$

[0055] 式中, α 表示每个键对查询矩阵的归一化注意力权重,V表示值矩阵;

[0056] 进一步地,S64中,融合特征图 Q_{fused} 的计算公式为:

$$[0057] \quad Q_{\text{fused}} = Q + O;$$

[0058] 式中,O表示加权后的输出特征,Q表示查询矩阵。

[0059] 本发明的有益效果是:本发明将交叉注意力机制与卷积注意力模块应用于分割网络架构设计中,依托U型网络骨架,使用卷积层与Swin Transformer Block并行提取特征,利用交叉注意力机制融合二者输出特征图,实现兼顾全局和局部细节特征。本发明利用管道注意力与空间注意力的结合降低卷积低级特征图中的噪声干扰,避免为深层网络引入过多噪声,缓解了噪声对分割结果的影响。

附图说明

[0060] 图1为基于神经网络的乳腺超声图像分割方法的流程图;

[0061] 图2为卷积特征提取模块的结构示意图。

具体实施方式

[0062] 下面结合附图对本发明的实施例作进一步的说明。

[0063] 如图1所示,本发明提供了一种基于神经网络的乳腺超声图像分割方法,包括以下步骤:

[0064] S1、采集乳腺超声图像,利用卷积层对乳腺超声图像依次进行卷积处理和展平处理;

[0065] S2、对处理后的乳腺超声图像进行特征提取,得到原始特征图;

[0066] S3、对原始特征图进行重塑处理和扁平化处理,得到展平特征图;

[0067] S4、将展平特征图输入至卷积特征提取模块中,得到低层特征图;

[0068] S5、将低层特征图输入至卷积注意力模块中,得到加权特征图;

[0069] S6、将原始特征图和加权特征图输入至交叉注意力模块中,得到最终特征图;

[0070] S7、将最终特征图依次输入至下采样卷积层和上采样卷积层,完成乳腺超声图像分割。

[0071] 在本发明实施例中,通过图像块划分和线性嵌入操作,将图像转为Swin Transformer块期望的输入格式。由于卷积模块和Swin Transformer块期望的输入格式存

在差异,因此通过特征图重塑和特征图扁平化以适应卷积模块输入。图像特征提取部分由Swin Transformer Block与卷积模块并行完成,并通过交叉注意力模块将对二者特征图进行特征融合。下采样旨在逐渐降低图像的空间分辨率,同时增加特征的深度,而上采样旨在从低分辨率的特征图中恢复出高分辨率的图像或特征图,以便进行进一步的处理或精确的预测。同时保留U型架构的跳跃连接结构,将编码器每一层的特征图传递给对应的解码器层,使得解码过程不仅仅依赖于从前一层传递过来的上采样特征图,还可以利用低层的原始特征。

[0072] 在本发明实施例中,S1中,在将图像输入到Swin Transformer块前,首先需要将图像划分为图像块,并通过线性嵌入将其转化为适应Swin Transformer块输入的形式,具体过程如下:

[0073] 卷积操作:使用一个卷积层。该卷积层的卷积核大小为 4×4 ,步长为4,输出通道数为C,将输入图像 $I \in \mathbb{R}^{H \times W \times 3}$ (其中H、W分别是图像的高度像素和宽度像素,3表示图像颜色通道)经过卷积处理后即可完成图像块的划分与线性嵌入,具体为: $Conv(I) \in \mathbb{R}^{\frac{H}{4} \times \frac{W}{4} \times C}$ 。

[0074] 展平输出:将卷积操作的输出展平后,得到图像张量 $(\frac{W}{4} \times \frac{H}{4}, 1, C)$ (宽为 $\frac{W}{4} \times \frac{H}{4}$,高为1,通道数为C),作为Swin Transformer块的输入。

[0075] S2中,采用已有Swin Transformer架构中的Swin Transformer Block进行特征提取。

[0076] S3中,为了将图像转为卷积特征提取模块所需要的输入格式,并在特征提取后还原原有格式,进行了特征图重塑和特征图扁平化操作。

[0077] 特征图重塑:将输入特征图 $(W_n \times H_n, 1, C_n)$ 输入至网络第n层,如 $W_1 = \frac{W}{4}, H_1 = \frac{H}{4}, C_1 = C$ 转为特征图 (W_n, H_n, C_n) 。

[0078] 特征图扁平化:将卷积特征提取模块的输出展平,即将特征图 (W_n, H_n, C_n) 转为特征图 $(W_n \times H_n, 1, C_n)$ 。

[0079] 如图2所示,在S4中,卷积特征提取模块包括第一标准卷积层、第一扩张卷积层、深度可分离卷积层、第二扩张卷积层、第二标准卷积层、残差卷积层和加法器;

[0080] 第一标准卷积层的输入端作为卷积特征提取模块的输入端,第一标准卷积层的输入端还与残差卷积层的输入端连接;第一标准卷积层的输出端和第一扩张卷积层的输入端连接;第一扩张卷积层的输出端和深度可分离卷积层的输入端连接;深度可分离卷积层的输出端和第二扩张卷积层的输入端连接;第二扩张卷积层的输出端和第二标准卷积层的输入端连接;第二标准卷积层的输出端和加法器的第一输入端连接;残差卷积层的输出端和加法器的第二输入端连接;加法器的输出端作为卷积特征提取模块的输出端。

[0081] 对于 3×3 标准卷积层,使用了核大小为3,步长为1,填充为1的卷积核,在不改变特征图大小的同时实现特征提取。对于模块中的两个扩张卷积层,分别使用了核大小为3,步长为1,填充为2,扩张因子为2与核大小为3,步长为1,填充为3,扩张因子为3的空洞卷积。使卷积核之间有2或3个像素的空隙,逐步增大卷积核的有效感受野。采用深度可分离卷积,利用深度卷积计算每个通道的特征,再使用逐点卷积处理每个位置的特征图,合成输出,以获得更细粒度的细节特征。使用 1×1 卷积作为残差连接的桥梁,允许原始特征图和卷积输出

特征图进行相加,避免梯度消失,促进信息流通。

[0082] 在本发明实施例中,S5包括以下子步骤:

[0083] S51、利用卷积注意力模块的通道注意力层对低层特征图进行全局平均池化和全局最大池化,得到第一通道描述符和第二通道描述符,并利用第一通道描述符和第二通道描述符对低层特征图进行处理;

[0084] S52、利用卷积注意力模块的空间注意力层对处理后低层特征图进行全局平均池化和全局最大池化,得到第一空间描述符和第二空间描述符,并利用第一空间描述符和第二空间描述符得到加权特征图。

[0085] 在本发明实施例中,S51中,第一通道描述符 M_{avg} 的计算公式为:

[0086] $M_{avg} = \text{AvgPool}(F)$;

[0087] 式中,F表示低层特征图,AvgPool($\cdot$)表示全局平均池化操作;

[0088] S51中,第二通道描述符 M_{max} 的计算公式为:

[0089] $M_{max} = \text{MaxPool}(F)$;

[0090] 式中,MaxPool($\cdot$)表示全局最大池化操作;

[0091] S51中,处理后低层特征图 F' 的表达式为:

[0092] $F' = F \cdot A_c$;

[0093] $A_c = \sigma(\text{FC}(\text{ReLU}(\text{FC}(M_{avg} + M_{max}))))$;

[0094] 式中, A_c 表示多层感知机网络中每个通道的注意力权重,ReLU($\cdot$)表示激活函数, $\sigma(\cdot)$ 表示Sigmoid激活函数,FC表示全连接层。

[0095] 在本发明实施例中,S52中,第一空间描述符 M_{avg}' 的计算公式为:

[0096] $M_{avg}' = \text{AvgPool}(F')$;

[0097] 式中, F' 表示处理后低层特征图,AvgPool($\cdot$)表示全局平均池化操作;

[0098] S52中,第二空间描述符 M_{max}' 的计算公式为:

[0099] $M_{max}' = \text{MaxPool}(F')$;

[0100] 式中,MaxPool($\cdot$)表示全局最大池化操作;

[0101] S52中,加权特征图 F'' 的表达式为:

[0102] $F'' = F' \cdot A_s$;

[0103] $A_s = \sigma(\text{Conv}([M_{avg}'; M_{max}']))$;

[0104] 式中, A_s 表示空间注意力权重图,Conv表示卷积操作, $\sigma(\cdot)$ 表示Sigmoid激活函数, $[\cdot; \cdot]$ 表示拼接操作。

[0105] 在本发明实施例中,S6包括以下子步骤:

[0106] S61、利用交叉注意力模块的线性层将原始特征图映射为查询矩阵,将加权特征图映射为键矩阵和值矩阵;

[0107] S62、计算查询矩阵和键矩阵之间的注意力分数矩阵,得到每个键对查询矩阵的归一化注意力权重;

[0108] S63、根据每个键对查询矩阵的归一化注意力权重以及值矩阵,计算加权后的输出特征;

[0109] S64、将加权后的输出特征和查询矩阵,得到融合特征图;

[0110] S65、通过线性变换将融合特征图映射回原始特征空间,得到最终特征图。

[0111] 在本发明实施例中,S62中,注意力分数矩阵A的表达式为:

$$[0112] \quad A = \frac{QK^T}{C};$$

[0113] 式中,Q表示查询矩阵,K表示键矩阵,T表示矩阵转置,C表示通道数;

[0114] S62中,每个键对查询矩阵的归一化注意力权重 α 的计算公式为:

$$[0115] \quad \alpha = \text{Softmax}(A);$$

[0116] 式中,Softmax($\bullet$)表示Softmax激活函数。

[0117] 在本发明实施例中,S63中,加权后的输出特征O的计算公式为:

$$[0118] \quad O = \alpha V;$$

[0119] 式中, α 表示每个键对查询矩阵的归一化注意力权重,V表示值矩阵;

[0120] 在本发明实施例中,S64中,融合特征图 Q_{fused} 的计算公式为:

$$[0121] \quad Q_{\text{fused}} = Q + O;$$

[0122] 式中,O表示加权后的输出特征,Q表示查询矩阵。

[0123] 在本发明实施例中,为了验证基于CNN与Swin Transformer乳腺超声图像分割网络的有效性,在BUSI乳腺超声数据集上进行模型训练和评估工作。BUSI数据集共有780张超声图像,其中437张为良性肿瘤,210张为恶性肿瘤,133张无肿瘤。去除BUSI数据集中的无肿瘤图片,并使用数据增强技术对BUSI数据集进行处理。为了平衡良性肿瘤和恶性肿瘤图像的数量,针对原数据集生成了2100张良性肿瘤数据增强图像,2100张恶性肿瘤增强图像,共4847张图像。随机选取2906张作为训练集,1294张作为测试集,647张原图像作为验证集。使用以上方法选取并构建数据集主要有三个原因:1) 由于BUSI数据集相对较小,为了避免网络过拟合,采用数据增强方法(如旋转、翻转、缩放等)增加图像的多样性,从而提高模型在不同场景下的表现,提高模型的泛化能力和性能;2) BUSI数据集在肿瘤边界和图片噪声方面具有挑战性;3) BUSI数据集在乳腺超声图像分割任务中具有广泛的应用。

[0124] 任务评价指标:

[0125] 在评价模型性能方面,使用Dice系数(Dice)、准确率(Acc)、交并比(IoU)以及豪斯多夫距离(HD)作为评价指标,Dice系数用于衡量预测与真实分割的相似度,准确率用于衡量正确分类像素占比,交并比用于衡量预测区域与真实区域的重叠程度,豪斯多夫距离用于衡量预测与真实边界间的最大误差,用于边界精度评估。

[0126] 算法参数设置:

[0127] 对于设计的分割网络架构,损失函数组合了Dice损失和交叉熵损失,权重均为0.5。优化器使用随机梯度下降(stochastic gradient descent,SGD)训练模型。在训练参数设置中,初始学习率(learning rate)设置为0.0005,并通过CosineAnnealing LR调度器逐步下降。模型在BUSI增强数据集上训练,batch size设置为8,输入分辨率为224x224,图像块大小为4x4,嵌入维度为96,Transformer头数随深度下降分别为[3,6,12,24],窗口大小为7,进行120个周期的训练以获得最终结果。

[0128] 结果比较:

[0129] 本方法(Ours)对比相同数据集(BUSI)下的当前先进网络架构(HCT-Net、MF-Net)与经典结构(Unet、DeepLabV3+、SwinUet)的结果如表1所示。

[0130] 表1

[0131]	网络架构	Dice 系数 (越大越好)	准确率 (越大越好)	交并比 (越大越好)	HD (越小越好)
	Unet	73.58	95.22	59.88	52.76
	DeepLabV3+	80.22	96.19	68.97	38.78
	SwinUnet	80.19	96.03	71.65	
	HCT-Net	83.11	96.94	71.84	34.55
	MF-Net	82.07	96.43	73.79	20.65
	本发明	84.59	98.11	76.43	17.13

[0132] 结果分析:

[0133] 在对比实验中,基于CNN与Swin Transformer结合的乳腺超声图像分割网络(Ours)在BUSI数据集上的表现显著优于现有的其他先进网络与经典分割网络。具体而言,本发明的Dice系数、准确率、交并比(IoU)和豪斯多夫距离(HD)等四个重要评价指标上均取得了最优结果。Dice系数达到84.59,比第二名高出1.48个百分点,显示出更强的分割精度;准确率达到98.11,比第二名高出1.17个百分点,表明模型在大多数像素上做出了正确的分类决策;交并比达到76.43,比最接近的MF-Net高出2.64个百分点,表明模型能够精确捕捉肿瘤的 shape 和位置;豪斯多夫距离为17.13,较MF-Net低3.52,显示出在肿瘤边界的精度上具备显著优势,能够有效减少边界误差。

[0134] 相比传统的网络如Unet和DeepLabV3+,本发明方法不仅在所有指标上都表现得更好,而且在边界精度和区域重叠度上有着明显的提高。例如,豪斯多夫距离比Unet低了35.63,显示出边界的高精度预测能力。整体而言,基于CNN与Swin Transformer的乳腺超声分割网络展示了极为突出的分割能力,能够更有效地处理乳腺超声图像中的噪声干扰,提供更准确和可靠的分割结果。

[0135] 本领域的普通技术人员将会意识到,这里所述的实施例是为了帮助读者理解本发明的原理,应被理解为本发明的保护范围并不局限于这样的特别陈述和实施例。本领域的普通技术人员可以根据本发明公开的这些技术启示做出各种不脱离本发明实质的其它各种具体变形和组合,这些变形和组合仍然在本发明的保护范围内。




图1




图2